

۱-

الف)

$$X = \begin{bmatrix} -1 & -1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix} \quad \vec{\mu} = \frac{\vec{x}_1 + \vec{x}_2 + \vec{x}_3}{3} = [0 \ 0] \Rightarrow \tilde{X} = X$$

$$\Rightarrow S = \frac{\tilde{X} \tilde{X}^T}{N} = \begin{bmatrix} \frac{2}{3} & \frac{2}{3} \\ \frac{2}{3} & \frac{2}{3} \end{bmatrix} \quad \text{eigenvalues of } S = \left\{ 0, \frac{4}{3} \right\} \rightarrow \lambda$$

$$\begin{bmatrix} \frac{2}{3} & \frac{2}{3} \\ \frac{2}{3} & \frac{2}{3} \end{bmatrix} \times \begin{bmatrix} V_1 \\ V_2 \end{bmatrix} = \frac{4}{3} \begin{bmatrix} V_1 \\ V_2 \end{bmatrix} \Rightarrow \begin{bmatrix} V_1 \\ V_2 \end{bmatrix} = \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = \text{first Principal component}$$

(.)

$$x_1 = \begin{bmatrix} -1 & -1 \end{bmatrix} \Rightarrow x'_1 = \begin{bmatrix} -1 & -1 \end{bmatrix} \times \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = \underline{\underline{[-\sqrt{2}]}}$$

$$x_2 = \begin{bmatrix} 0 & 0 \end{bmatrix} \Rightarrow x'_2 = \begin{bmatrix} 0 & 0 \end{bmatrix} \times \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = \underline{\underline{[0]}}$$

$$x_3 = \begin{bmatrix} 1 & 1 \end{bmatrix} \Rightarrow x'_3 = \begin{bmatrix} 1 & 1 \end{bmatrix} \times \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = \underline{\underline{[\sqrt{2}]}}$$

$$\Rightarrow \text{Variance} = \frac{(-\sqrt{2}-0)^2 + (0-0)^2 + (\sqrt{2}-0)^2}{3} = \underline{\underline{\frac{4}{3}}}$$

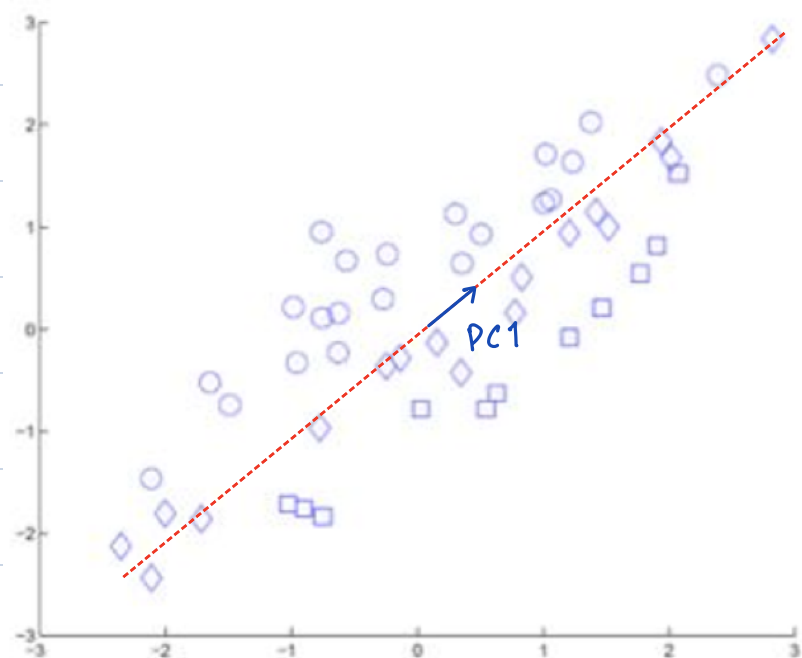
(.)

$$\hat{x}_1 = \begin{bmatrix} \sqrt{2} \end{bmatrix} \times \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = \begin{bmatrix} -1 & -1 \end{bmatrix} = x_1$$

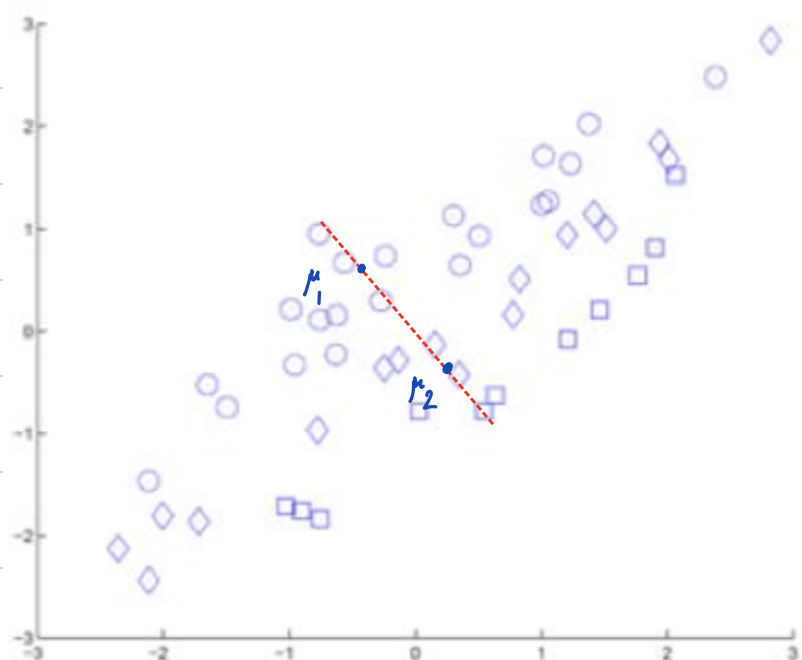
$$\hat{x}_2 = \begin{bmatrix} 0 \end{bmatrix} \times \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = \begin{bmatrix} 0 & 0 \end{bmatrix} = x_2 \Rightarrow \underline{\underline{\text{reconstruction error} = 0}}$$

$$\hat{x}_3 = \begin{bmatrix} \sqrt{2} \end{bmatrix} \times \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = \begin{bmatrix} 1 & 1 \end{bmatrix} = x_3$$

-2
الف



ب



الف) از آنجایی که تابع هزینه الگوریتم K-means با گذشت iteration ها به صورت *monotonically decreasing* است، ماتریس γ یکسان را بیش از یک بار مشاهده نمی کنیم. با این که ماتریس γ 2^{mk} خانه دارد، ولی در هر γ به یک خوشه n assign می شود، تعداد حالت های مختلف γ برابر با k^n است. بنابراین الگوریتم در حداکثر k^n قدم به پایان می رسد.

ب)

$$\begin{aligned} \sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} w_j(x) + nB(x) &= \sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} \|x_i - \mu_j\|^2 + \sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} \|\mu_j - \hat{x}\|^2 \\ &= \sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} (\|x_i - \mu_j\|^2 + \|\mu_j - \hat{x}\|^2) = \sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} (x_i^T x_i - \hat{x}^T \hat{x} - 2x_i^T \hat{x} + 2x_i^T \mu_j + \mu_j^T \mu_j - 2x_i^T \mu_j - 2\hat{x}^T \mu_j) \\ &= \sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} [(x_i^T x_i + \hat{x}^T \hat{x} - 2x_i^T \hat{x}) + (\mu_j^T \mu_j - 2\mu_j^T x_i - 2\mu_j^T \hat{x} + 2x_i^T \mu_j)] \\ &= nT(x) + \underbrace{\sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} (\mu_j^T \mu_j - 2\mu_j^T x_i - 2\mu_j^T \hat{x} + 2x_i^T \mu_j)}_A \end{aligned}$$

دقت کنید که $\left[\sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} w_j(x) \right]$ که در ابتدا استفاده کردیم، برابر با $T \times n$ است. بنابراین با کمینه کردن T و nT نیز کمینه می شود (چون n ثابت است). می دانیم $T(x)$ ثابت است و بنابراین $nT(x)$ نیز ثابت است. و با صرف ثابت بودن A در فرمول بالا، می توان گفت کمینه کردن $\left[\sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} w_j(x) \right]$ معادل با بیشینه کردن $nB(x)$ و در نتیجه بیشینه کردن $B(x)$ است. بنابراین الگوریتم K-means با بیشینه شدن انحراف بین خوشه ای (به شکل تقریبی) و کمینه شدن میانگین وزن دار مقادیر درون خوشه ای می شود.

پ) با استقرار نشان می‌دهیم که $J_{min}(k+1)$ کمتر یا مساوی با $J_{min}(k)$ است. وزن کنید با انتخاب k دلتا Δ الگوریتم را

اجرای کنید و بعد از همگرای به $J_{min}(k)$ رسم. حال وزن کنید یک centroid پس اضافه می‌کنیم و آن را بررسی می‌کنیم از k تا centroid قبل قرار می‌دهیم و تعدادی از اضافه آن خنثی را به صورت تصادفی به خنثی جدید اضافه می‌کنیم. حال $J(k+1)$ برابر با $J_{min}(k)$ شد و با اجرای الگوریتم، این مقدار نیز به شکل Monotonic کاهش می‌یابد، بنابراین $J_{min}(k)$ و $J_{min}(k+1)$ برابر این انتخاب k بر اساس کمینه شدن J به معنیست چون با این روش همواره k بزرگ تر انتخاب می‌شوند و با افزایش k می‌توان J را کاهش داد.

(الف)

$$P(x, z; \theta) = (\pi p_r^x (1-p_r)^{1-x})^z ((1-\pi) p_b^x (1-p_b)^{1-x})^{1-z}$$

(ب)

$$\ln L_c(\theta) = \sum_{i=1}^m [z_i (\ln(\pi) + x_i \ln(p_r) + (1-x_i) \ln(1-p_r)) + (1-z_i) (\ln(1-\pi) + x_i \ln(p_b) + (1-x_i) \ln(1-p_b))]$$

(ج)

$$\frac{\partial \ln L_c(\theta)}{\partial p_b} = 0 \Rightarrow \sum_{i=1}^m (1-z_i) \left(\frac{x_i}{p_b} - \frac{1-x_i}{1-p_b} \right) = 0 \Rightarrow \hat{p}_b = \frac{\sum_{i=1}^m (1-z_i) x_i}{\sum_{i=1}^m (1-z_i)}$$

$$\frac{\partial \ln L_c(\theta)}{\partial p_r} = 0 \Rightarrow \sum_{i=1}^m z_i \left(\frac{x_i}{p_r} - \frac{1-x_i}{1-p_r} \right) = 0 \Rightarrow \hat{p}_r = \frac{\sum_{i=1}^m z_i x_i}{\sum_{i=1}^m z_i}$$

$$\frac{\partial \ln L_c(\theta)}{\partial \pi} = 0 \Rightarrow \sum_{i=1}^m \left(\frac{z_i}{\pi} - \frac{1-z_i}{1-\pi} \right) = 0 \Rightarrow \hat{\pi} = \frac{\sum_{i=1}^m z_i}{m}$$

(د)

$$P(z_i=1 | x_i=x_i; \theta^t) = \frac{P(x_i=x_i | z_i=1; \theta) P(z_i=1; \theta)}{P(x_i=x_i; \theta)} = \frac{\pi p_r^{x_i} (1-p_r)^{1-x_i}}{\pi p_r^{x_i} (1-p_r)^{1-x_i} + (1-\pi) p_b^{x_i} (1-p_b)^{1-x_i}}$$

(هـ)

بالتتابع به بخش ب

$$p_b^{t+1} = \frac{\sum_{i=1}^m (1-x_i^t) x_i^t}{\sum_{i=1}^m (1-x_i^t)}, \quad p_r^{t+1} = \frac{\sum_{i=1}^m x_i^t}{\sum_{i=1}^m x_i^t}, \quad \pi^{t+1} = \frac{\sum_{i=1}^m x_i^t}{m}$$